

Next Gen Tech

Projeto Final · Bootcamp Análise de Dados

BUSINESS INTELLIGENCE

Eficiência Comercial e Maximização de Margem Operacional no Varejo Digital

Projeto Eficiência Comercial no Varejo Digital

Pipeline completo de dados utilizando SQL, MySQL e Power BI

GRUPO 1

Larissa Olimpio · Nivaldo Arruda · Andreza Oliveira · Jéssica Brenda

Julho de 2026

Índice

01	Introdução	3
02	Objetivos do Projeto	4
03	Base de Dados	5
04	Engenharia e Modelagem de Dados	6
05	Modelagem Dimensional	8
06	Construção do Banco de Dados	11
07	Desenvolvimento das Queries SQL	12
08	Construção da Dashboard	15
09	Principais Insights	18
10	Conclusão	20

Introdução

Este projeto teve como objetivo transformar uma base de dados transacional bruta em uma solução completa de Business Intelligence, capaz de apoiar decisões estratégicas de negócio. Partindo de um conjunto de dados de vendas de um marketplace digital, o trabalho percorreu todas as etapas de um pipeline moderno de dados: da obtenção e diagnóstico da base à entrega de uma dashboard interativa com insights acionáveis.

O desenvolvimento foi conduzido seguindo um fluxo estruturado, que reflete boas práticas de mercado para projetos de analytics:

- ▶ Obtenção e diagnóstico dos dados brutos
- ▶ Modelagem relacional da base (normalização)
- ▶ Criação do banco de dados em MySQL
- ▶ Construção das consultas SQL analíticas
- ▶ Importação e tratamento dos dados no Power BI
- ▶ Criação do modelo dimensional (Star Schema)
- ▶ Desenvolvimento de medidas DAX e tabela calendário
- ▶ Construção da dashboard executiva
- ▶ Geração de insights estratégicos para o negócio

O fio condutor de toda a análise é a eficiência comercial e a maximização da margem operacional em um ambiente de varejo digital — ou seja, compreender não apenas quanto a empresa vende, mas onde, para quem e com que grau de concentração de risco essas vendas acontecem, de forma a orientar decisões sobre expansão, mix de produtos e estratégias comerciais.

ESCOPO TÉCNICO DO PROJETO

SQL (MySQL Workbench) para modelagem relacional e consultas analíticas · Power BI para modelagem dimensional, DAX e visualização · Star Schema como arquitetura de dados · Storytelling de dados aplicado à construção dos insights finais.

Objetivos do Projeto

O projeto foi orientado por um conjunto de perguntas de negócio que guiaram tanto a modelagem dos dados quanto a construção dos indicadores e visualizações. O objetivo central foi transformar dados transacionais em respostas diretas para essas perguntas, permitindo que qualquer stakeholder, técnico ou não, compreenda rapidamente a saúde comercial da operação.

Perguntas estratégicas respondidas

Essas perguntas se conectam diretamente aos indicadores construídos na dashboard — receita total, ticket médio, unidades vendidas, receita por região e por categoria, distribuição por forma de pagamento e correlação entre preço e volume — e aos insights estratégicos apresentados no capítulo 9 deste documento.

- ▶ Qual categoria de produto gera a maior receita para o negócio?
- ▶ Quais regiões apresentam o melhor desempenho comercial?
- ▶ Existe concentração de receita em alguma categoria ou região específica?
- ▶ Há sazonalidade perceptível no comportamento de vendas ao longo do ano?
- ▶ O preço unitário do produto influencia o volume de unidades vendidas?
- ▶ Existem oportunidades claras de expansão geográfica ou de categoria?
- ▶ Como o ticket médio pode ser aumentado?
- ▶ Quais categorias possuem maior participação relativa nas vendas totais?

Base de Dados

A base de dados utilizada neste projeto foi obtida na plataforma Kaggle, um repositório público amplamente utilizado pela comunidade de dados para disponibilização de datasets voltados a estudos, prototipagem de análises e portfólios de Data Analytics.

DATASET UTILIZADO

Online Sales Dataset – Popular Marketplace Data

Disponível em: kaggle.com/datasets/shreyanshverma27/online-sales-dataset-popular-marketplace-data

O dataset original reúne informações transacionais de vendas realizadas em um marketplace digital, contemplando os seguintes campos principais:

- ▶ Identificação da transação
- ▶ Data da venda
- ▶ Produto e categoria do produto
- ▶ Quantidade de unidades vendidas
- ▶ Preço unitário
- ▶ Receita gerada pela transação
- ▶ Região do cliente
- ▶ Forma de pagamento utilizada

No total, a base contempla 240 transações registradas entre janeiro e agosto de 2024, o que possibilitou tanto análises de composição (receita por categoria, por região, por forma de pagamento) quanto análises temporais (evolução mensal de receita e indícios de sazonalidade).

Fonte dos dados: Kaggle — Online Sales Dataset (Popular Marketplace Data), autor shreyanshverma27.

Engenharia e Modelagem de Dados

Na sua forma original, a base de dados era composta por uma única tabela plana, reunindo em cada linha todas as informações da transação: produto, categoria, região, forma de pagamento, preço, quantidade e receita. Essa estrutura, embora simples de manusear em uma primeira exploração, apresenta problemas relevantes para um ambiente analítico:

- ▶ Alta redundância de dados (nomes de produto, categoria, região e forma de pagamento repetidos em cada linha)
- ▶ Maior propensão a inconsistências de digitação e integridade
- ▶ Dificuldade de manutenção e evolução do modelo
- ▶ Desempenho inferior em consultas analíticas mais complexas
- ▶ Incompatibilidade com boas práticas de modelagem para ferramentas de BI

Para corrigir essas limitações, foi realizada uma normalização da base utilizando SQL, com o objetivo de eliminar redundâncias e preparar os dados para uma modelagem dimensional eficiente no Power BI. O processo seguiu as seguintes etapas:

Etapas da normalização

- ▶ Separação da tabela original em múltiplas tabelas especializadas
- ▶ Criação das tabelas de dimensão (produtos, regiões, formas de pagamento)
- ▶ Criação da tabela fato, contendo as métricas transacionais (unidades, preço, receita)
- ▶ Definição das chaves primárias (Primary Keys) em cada tabela de dimensão
- ▶ Definição das chaves estrangeiras (Foreign Keys) na tabela fato, conectando-a às dimensões
- ▶ Estabelecimento dos relacionamentos entre as tabelas
- ▶ Garantia de integridade referencial entre fato e dimensões

Vantagens da modelagem adotada

A migração de uma tabela única para um modelo relacional normalizado trouxe ganhos diretos para o restante do projeto:

- ▶ Redução de redundância: atributos descritivos (nome do produto, categoria, região) passam a existir uma única vez, nas tabelas de dimensão

- ▶ Melhor organização dos dados: separação clara entre o que é métrica (fato) e o que é atributo descritivo (dimensão)
- ▶ Maior desempenho: tabelas menores e chaves indexadas tornam consultas e relacionamentos mais eficientes
- ▶ Facilidade de manutenção: alterações em um atributo (ex.: nome de uma região) precisam ser feitas em um único lugar
- ▶ Escalabilidade: o modelo comporta crescimento do volume de dados e adição de novas dimensões sem redesenho estrutural

Modelagem Dimensional

Esta seção apresenta a evolução da modelagem de dados em dois estágios: primeiro o modelo relacional construído no MySQL Workbench, e em seguida sua tradução prática para o modelo dimensional implementado no Power BI.

Modelo relacional (MySQL Workbench)




Figura 1 – Modelo DER desenvolvido e exportado através do MySQL Workbench.

O diagrama entidade-relacionamento (DER) acima materializa a normalização descrita no capítulo anterior. A tabela central **sales** concentra as métricas transacionais — quantidade de unidades, preço unitário e receita — além das chaves estrangeiras que a conectam às três tabelas de dimensão:

- ▶ **products** — chave primária *product_id*, contendo nome e categoria do produto
- ▶ **regions** — chave primária *region_id*, contendo a região do cliente
- ▶ **payments** — chave primária *payment_id*, contendo o método de pagamento

Cada uma dessas dimensões se relaciona com a tabela **sales** por meio de relacionamentos 1:N (um produto, uma região ou uma forma de pagamento pode estar associado a diversas transações), o que caracteriza uma estrutura já orientada a um modelo estrela, preparando o terreno para a modelagem dimensional dentro do Power BI.

Modelo dimensional (Power BI)




Figura 2 – Modelo dimensional implementado no Power BI, derivado da modelagem relacional construída no MySQL.

O modelo dimensional implementado no Power BI representa a aplicação prática da estrutura desenhada no MySQL, seguindo o padrão **Star Schema (Modelo Estrela)**: uma tabela fato central conectada a tabelas de dimensão por relacionamentos 1:N, favorecendo desempenho, clareza do modelo e facilidade na construção de medidas e visuais.

Fact_Sales — Tabela fato

Reúne as métricas transacionais (receita, unidades, preço unitário) e as chaves de ligação com as dimensões (produto, região, pagamento), além dos atributos de data utilizados na análise temporal.

Tabelas de dimensão

- **Dim_Products** — categoria, identificador e nome do produto

- ▶ **Dim_Regions** — identificador e nome da região
- ▶ **Dim_Payments** — identificador e método de pagamento

Medidas

Tabela dedicada exclusivamente ao armazenamento das medidas DAX criadas para o projeto — entre elas *AverageTicket*, *AverageUnitsSold*, *BestSalesMonth*, *ChampionCategoryRevenue*, *ChampionCategoryUnits* e *CorrelationInterpretation* — mantendo o modelo organizado e separando claramente dados de cálculos.

DimCalendarDAX

Tabela calendário construída via DAX, detalhada na próxima seção, responsável por garantir consistência em todas as análises temporais do modelo.

Essa estrutura em estrela — fato ao centro, dimensões ao redor — é a arquitetura recomendada pela Microsoft para modelos Power BI, pois simplifica os relacionamentos, evita ambiguidade em cálculos DAX e melhora significativamente a performance de consultas em relação a modelos flat ou snowflake desnecessariamente complexos.

Construção da tabela calendário

Para garantir consistência em todas as análises temporais, foi desenvolvida uma tabela calendário utilizando DAX (DimCalendarDAX), com os seguintes campos:

- ▶ **Date** — data completa
- ▶ **Year** — ano da transação
- ▶ **Month Nome** — nome do mês por extenso
- ▶ **Month number** — número do mês, usado para ordenação
- ▶ **Month Year** — combinação de mês e ano

POR QUE USAR UMA TABELA CALENDÁRIO

A criação de uma tabela calendário dedicada é considerada uma boa prática consolidada em projetos Power BI. Ela garante a ordenação correta dos meses (evitando ordenação alfabética indevida), habilita funções de inteligência temporal do DAX (como comparações ano a ano ou mês a mês), melhora o desempenho das medidas que dependem de contexto de data, e mantém o modelo mais organizado, desacoplando a lógica de tempo da tabela fato.

Construção do Banco de Dados

Após a conclusão da modelagem relacional, todas as tabelas foram efetivamente criadas no MySQL, servindo como camada de sustentação para as etapas seguintes do projeto. O banco de dados relacional cumpriu quatro funções principais ao longo do desenvolvimento:

- ▶ Consultas analíticas — execução das queries SQL utilizadas para responder às perguntas de negócio
- ▶ Validação dos dados — verificação de consistência, integridade referencial e ausência de duplicidades
- ▶ Criação dos indicadores — construção das métricas que posteriormente alimentaram as medidas DAX
- ▶ Preparação do modelo para o Power BI — estruturação das tabelas de forma que a importação para o modelo dimensional fosse direta e consistente

Trabalhar a análise diretamente no banco relacional — antes de levar os dados ao Power BI — permitiu validar hipóteses de negócio de forma rápida via SQL, reduzindo retrabalho posterior na camada de DAX e assegurando que o modelo dimensional herdasse uma base de dados já íntegra e consistente.

Desenvolvimento das Queries SQL

Diversas consultas SQL foram desenvolvidas ao longo do projeto para responder a perguntas estratégicas de negócio diretamente sobre o banco relacional, antes mesmo da construção das medidas DAX no Power BI. Esse trabalho analítico em SQL cumpriu um papel duplo: validar hipóteses de forma ágil e servir de base conceitual para os indicadores posteriormente implementados na dashboard.

Entre as análises realizadas ao longo do projeto, destacam-se:

- ▶ Receita por região e por categoria
- ▶ Ticket médio
- ▶ Participação relativa das categorias no faturamento
- ▶ Evolução temporal da receita
- ▶ Produtos mais vendidos e Curva ABC
- ▶ Correlação entre preço e quantidade vendida
- ▶ Distribuição regional de vendas
- ▶ Comparação de desempenho entre categorias

A seguir estão detalhadas as consultas mais relevantes utilizadas nas análises apresentadas neste relatório.

Categoria com maior geração de receita

```
SELECT
    p.category,
    SUM(s.revenue) AS total_revenue
FROM sales s
JOIN products p ON s.product_id = p.product_id
GROUP BY p.category
ORDER BY total_revenue DESC
LIMIT 1;
```

Esta consulta agrupa a receita total por categoria de produto, unindo a tabela fato **sales** à dimensão **products** através de *product_id*. O resultado, ordenado de forma decrescente e limitado ao primeiro registro, identifica diretamente a categoria líder em faturamento — base para o insight sobre a dominância de Electronics apresentado no capítulo 9.

Categoria com maior volume de unidades vendidas

```
SELECT
  p.category,
  SUM(s.units) AS total_units
FROM sales s
JOIN products p ON s.product_id = p.product_id
GROUP BY p.category
ORDER BY total_units DESC
LIMIT 1;
```

Estruturalmente semelhante à consulta anterior, porém substituindo a métrica de receita por unidades vendidas. Esta comparação lado a lado — receita líder versus volume líder — foi o ponto de partida para o insight de que volume não necessariamente significa maior faturamento.

Ticket médio

```
SELECT
  AVG(revenue) AS average_ticket
FROM sales;
```

Cálculo direto da média de receita por transação sobre toda a tabela fato, utilizado como indicador de referência para o cartão Ticket Médio exibido na dashboard e como base de comparação para as estratégias de cross-selling e upselling discutidas nos insights.

Curva ABC de produtos

```

WITH ProductRevenue AS (
    SELECT
        p.product_name,
        SUM(s.revenue) AS total_revenue
    FROM sales s
    JOIN products p ON s.product_id = p.product_id
    GROUP BY p.product_name
),
RunningTotal AS (
    SELECT
        product_name,
        total_revenue,
        SUM(total_revenue) OVER (ORDER BY total_revenue DESC) AS
cumulative_revenue,
        SUM(total_revenue) OVER () AS grand_total
    FROM ProductRevenue
)
SELECT
    product_name,
    total_revenue,
    (cumulative_revenue / grand_total) * 100 AS cumulative_percentage,
    CASE
        WHEN (cumulative_revenue / grand_total) <= 0.80 THEN 'A'
        WHEN (cumulative_revenue / grand_total) <= 0.95 THEN 'B'
        ELSE 'C'
    END AS abc_class
FROM RunningTotal;

```

Esta é a consulta analiticamente mais sofisticada do projeto, utilizando Common Table Expressions (CTEs) encadeadas e funções de janela (window functions). A primeira CTE (ProductRevenue) calcula a receita total por produto. A segunda (RunningTotal) utiliza *SUM() OVER (ORDER BY total_revenue DESC)* para calcular a receita acumulada em ordem decrescente, além do total geral via *SUM() OVER ()* sem particionamento. Por fim, a consulta principal calcula o percentual acumulado de cada produto sobre o total e o classifica em três faixas segundo a metodologia clássica de Curva ABC: produtos A (até 80% da receita acumulada), B (de 80% a 95%) e C (os 5% finais). Essa classificação permite priorizar os produtos de maior impacto financeiro em decisões de estoque, precificação e esforço comercial.

Construção da Dashboard

A dashboard final foi estruturada em duas páginas complementares no Power BI, cada uma respondendo a um conjunto específico de perguntas de negócio, com filtros interativos de **região** e **categoria** disponíveis em ambas as páginas.

Página 1 — Visão Executiva



Figura 3 – Página "Visão Executiva" da dashboard, com indicadores gerais de desempenho comercial.

Esta página tem o objetivo de oferecer um panorama geral e imediato da saúde comercial da operação, por meio de cinco cartões de KPI seguidos de três visuais analíticos:

- ▶ **Cartões de KPI** (Receita Total, Unidades Vendidas, Ticket Médio, Quantidade de Pedidos e Variação Jan → Ago) — escolhidos por serem as métricas de leitura mais rápida para qualquer stakeholder, permitindo capturar o estado geral do negócio em segundos
- ▶ **Gráfico de barras horizontais — Receita por Região** — a orientação horizontal favorece a leitura dos nomes das regiões e a comparação direta de magnitude entre elas
- ▶ **Gráfico de barras horizontais — Receita Total por Categoria** — mesma lógica de leitura, aplicada à comparação entre as seis categorias de produto

- **Gráfico de linhas — Desempenho Mensal de Receita por Categoria** — o visual de linha foi escolhido por ser o mais adequado para evidenciar tendência e sazonalidade ao longo do tempo, com uma série por categoria

O indicador de **Variação (Jan → Ago)** de **-74%** chama atenção imediata para a queda de receita entre o início e o fim do período analisado, e é o ponto de partida para a discussão de sazonalidade apresentada no capítulo de insights.

Página 2 — Clientes e Mercado




Figura 4 – Página "Clientes e Mercado" da dashboard, com indicadores de concentração, distribuição regional e comportamento de compra.

A segunda página aprofunda a análise em direção ao comportamento de mercado, concentração de receita e relação entre preço e volume:

- **Cartões de contexto** (Região Mais Lucrativa, Impacto da Região Líder, Maior Volume em Unidades, Impacto de Eletrônicos e Pagamento Predominante) — traduzem os números da página anterior em leitura direta de concentração e risco
- **Gráfico de barras — Distribuição de Unidades Vendidas por Região** — segmentado por categoria, permite comparar não apenas o volume total por região, mas sua composição
- **Gráfico de rosca (donut) — Distribuição por Forma de Pagamento** — o formato circular é adequado para leitura de participação percentual entre poucas categorias (Cartão de Crédito, Cartão de Débito e PayPal)

- **Gráfico de dispersão — Correlação de Vendas por Preço vs. Volume** — com linha de tendência, é o visual mais apropriado para investigar relação de causa/efeito entre duas variáveis contínuas (preço e unidades vendidas)

A escolha consistente de uma paleta monocromática em tons de roxo, do mais claro ao mais escuro, para diferenciar categorias e séries, reforça a identidade visual da dashboard e mantém o foco do usuário na leitura dos dados, e não em elementos decorativos.

Principais Insights

A partir da análise cruzada dos dados de receita, volume, região e forma de pagamento, foram identificados sete insights estratégicos com potencial direto de aplicação em decisões de negócio.

1 Electronics domina o faturamento

A categoria Electronics é responsável pela maior parcela da receita total da empresa (US\$ 3,1M, cerca de 44% do faturamento). Embora outras categorias — como Clothing e Books — apresentem volume elevado de unidades vendidas, Electronics possui maior valor agregado por transação e, conseqüentemente, maior impacto financeiro absoluto.

2 Forte concentração de receita

A receita da categoria Electronics está fortemente concentrada na região da América do Norte, que sozinha responde por 46,4% do faturamento total. Essa concentração representa um risco estratégico: qualquer instabilidade econômica, logística ou competitiva nessa região específica pode impactar de forma significativa o resultado da empresa como um todo.

3 Oportunidade de expansão

Dado o excelente desempenho de Electronics na América do Norte, existe uma oportunidade concreta de expansão para Ásia e Europa, regiões onde atualmente predominam outras categorias de produto. Essa expansão reduziria a dependência de uma única região e diversificaria as fontes de receita da empresa.

4 Volume não significa maior faturamento

Clothing e Books lideram em quantidade de unidades vendidas — Clothing registrou aproximadamente 145 unidades na Ásia, e Books cerca de 114 unidades na América do Norte. Ainda assim, é Electronics que concentra a maior geração de receita, evidenciando que volume de vendas e valor gerado são dimensões distintas do desempenho comercial.

5 Estratégia para aumento do ticket médio

Clothing e Books, por seu grande volume de vendas, podem funcionar como porta de entrada para estratégias de cross-selling e upselling. O alto tráfego de compra nessas categorias representa uma oportunidade de oferecer produtos de maior valor agregado em conjunto, elevando o ticket médio sem depender exclusivamente da aquisição de novos clientes.

6

Identificação de outliers

A análise identificou a presença de valores atípicos (outliers) na base — o caso mais relevante refere-se a um produto da categoria Clothing vendido em aproximadamente 10 unidades em uma única transação, valor muito acima do padrão observado nas demais vendas. Esse registro foi considerado durante a análise para evitar distorções na interpretação dos resultados agregados.

7

Sazonalidade

Observou-se uma redução significativa na receita ao longo do segundo semestre, refletida na queda de -74% entre janeiro e agosto identificada na Visão Executiva. Há um indicativo de recuperação no mês de agosto, mas essa variação ainda demanda investigação adicional — possíveis causas incluem sazonalidade de consumo, campanhas promocionais, disponibilidade de estoque ou mudanças no comportamento do consumidor.

Conclusão

O projeto percorreu, de ponta a ponta, todas as etapas de um pipeline moderno de Business Intelligence: partindo de uma base transacional bruta obtida no Kaggle, passou pela normalização e modelagem relacional no MySQL, pela construção de um modelo dimensional em Star Schema no Power BI, pelo desenvolvimento de medidas DAX e de uma tabela calendário dedicada, até chegar à construção de uma dashboard executiva de duas páginas.

Mais do que um exercício técnico, a solução desenvolvida permitiu identificar riscos de concentração (dependência de Electronics e da América do Norte), oportunidades de expansão geográfica e de categoria, padrões de comportamento de consumo (dissociação entre volume e receita) e possíveis estratégias para maximização da margem operacional, como o uso de categorias de alto volume para ações de cross-selling e upselling.

Do ponto de vista técnico, o projeto demonstra a aplicação prática e integrada de conceitos de modelagem de dados relacional, SQL avançado (CTEs, funções de janela, agregações), modelagem dimensional, DAX e storytelling de dados — competências centrais para a atuação como Analista de Dados em ambientes corporativos.